

Portfolio

웹 크롤링 기반 데이터 수집 체계를 구축해 데이터 기반 의사결정 프로세스로 전환한 경험이 있는
데이터 분석가 박혜림입니다

Name. 박혜림

Contact. 010-3080-8037

E-mail. limmil1103@gmail.com

Github. <https://github.com/hyelimmm-git>

PROFILE

박혜림

웹 크롤링 기반 데이터 수집 체계를 구축해 직관 중심의 업무를 데이터 기반 의사결정 프로세스로 전환한 경험이 있습니다.
Python·SQL 기반 데이터 전처리, 분석, 모델링 역량을 바탕으로
리워드 광고 운영 기준 수립, 전자상거래 배송지연과 리뷰스코어 상관관계 분석 프로젝트를 수행했으며,
비즈니스 문제를 데이터로 해결하는 데이터 분석가를 지향합니다.

경력사항

순ENT 음악사업부 인턴
2025.06 ~ 2025.08 (2개월)

우리홈쇼핑 DB생명 TM
2023.03 ~ 2023.09 (7개월)

학력사항

건국대학교 문화콘텐츠학과 졸업
2018.03 ~ 2024.02

활동내역

[KDT 기초역량훈련]
내일배움캠프 데이터 분석 11기 수료
2025.12 ~ 2026.05 (5개월)

- 파이썬, SQL, 통계 및 머신러닝을 학습
- 분석 프로젝트를 주도적으로 진행하며
비즈니스 문제 해결 역량을 강화

어학 및 자격증

SQLD
2025.12 취득

TOEIC 910점
2025.05 취득

SOFT SKILL



문제 정의 능력

모호한 비즈니스 이슈를 측정 가능한 분석 문제로 구체화하였습니다.
문제를 데이터 관점에서 재정의를 하여 해결 방안을 도출하였습니다.



협업 및 리더십

팀원들과 적극적으로 소통하며 프로젝트를 추진하였습니다.
목표 설정부터 역할 분배, 일정 관리까지 주도적으로 수행하였습니다.



커뮤니케이션

분석 결과를 비즈니스 언어로 재해석하여 이해관계자가
쉽게 이해하도록 전달하였습니다.

프로젝트

데이터 기반 광고 운영 의사결정 지원 시스템 구축

평가 기준 부재, 광고 분류 체계의 혼재, 사후 대응 중심 운영 문제를 해결하고자 BERTopic 기반 광고 재분류 체계, 광고 품질 평가 모델, 조기 부진 예측 모델을 구축하였으며, 운영자가 광고 현황을 모니터링하고 의사결정을 지원받을 수 있도록 Streamlit 대시보드와 AI Agent를 개발하였습니다. 광고 운영 전 과정을 데이터 기반으로 지원하는 의사결정 체계를 설계하는 것을 목표로 하였습니다.

수행 기간 2026 . 04 ~ 2026 . 05 (1개월)

참여 인원 5명

사용 기술 DuckDB, Python, Polars, Pandas, Scipy, Scikit-Learn, BERTopic, XGBoost, LightGBM, Streamlit

본인 역할 데이터 전처리 및 EDA 수행, BERTopic 광고 재분류
광고 품질 점수화 모델 및 조기 부진 예측 모델 구축
분석 결과 발표

핵심 산출물

- 광고품질점수 모델 : S/A/B/C/D 등급화
- 조기 점검 예측 모델 : D+3 기준
- BERTopic 기반 광고 유형 재분류 기준 : 매체형/행동형 기준 분리
- 광고 운영 의사결정 지원 대시보드

-Ive

전체 광고 현황 오버뷰

분석 범위: 2025-01-26 ~ 2025-05-25 (전체 기간)

페이지 2/24, 1/2건



■ 당일 실적-평점 ■ 주일 --- 평균 KPI값


경도 관망 - 건금 709·주익 706
N/A 평가 대상 기준: 적당히 500건 이하 (가려지지 않음)

TOP 10 의존도 49%
전주수 상위 10개 광고의 전주 점유율

상세 보기

순위	광고명	광고 유형	매체	클릭수	인도수	CVR	광고에 대해 평균수익률	평균율
1	새로운편지	행동형	PC	222,061	117,410	61.2%	51.2%	1.3%
2	조조복음	행동형	PC	195,111	10,122	50.1%	51.4%	6.2%
3	일종비	행동형	PC	117,092	35,489	72.5%	51.4%	5.8%
4	조조복음	행동형	PC	107,351	10,203	42.8%	51.4%	5.4%
5	일종비	행동형	PC	106,977	10,109	54.2%	51.4%	4.7%
6	새로운편지	행동형	PC	112,620	10,207	49.1%	51.2%	4.2%
7	북한도시	행동형	PC	106,109	10,101	44.1%	51.2%	4.2%
8	북한도시	행동형	PC	112,100	10,000	39.1%	51.0%	4.1%
9	군수 지부지·행정청 496	행동형	PC	10,101	47,002	54.1%	51.2%	3.2%
10	[간편결제] 마이신 도커	행동형	PC	10,101	10,101	39.1%	51.2%	3.0%

시간대 × 요일 CVR 히트맵




전체 기간 CVR Top 10

CVR 내림차순 - 클릭 10건 이상

순위	광고명	광고 유형	매체	클릭수	인도수	CVR	CMA	평균수익률
1	ROSCA 지리정보 2인 1도	행동형	PC	11	11	100.0%	120.0%	1.0%
2	최대 77% 할인 특가세팅 특가	행동형	PC	104	104	91.0%	11.0%	11.0%
3	최대 77% 할인 특가세팅 특가	행동형	PC	419	419	91.0%	11.0%	11.0%
4	우유 우유세팅 특가세팅 특가	행동형	PC	419	419	91.0%	11.0%	11.0%
5	[간편결제] 마이신 도커 2025.05.04 10	행동형	PC	45	45	91.0%	11.0%	11.0%
6	스타트업스 마이신 도커	행동형	PC	1,000	1,000	91.0%	11.0%	11.0%
7	[간편결제] 마이신 도커 2025.05.04 10	행동형	PC	45	45	91.0%	11.0%	11.0%
8	우유 우유세팅 특가세팅 특가	행동형	PC	419	419	91.0%	11.0%	11.0%
9	[간편결제] 마이신 도커 2025.05.04 10	행동형	PC	45	45	91.0%	11.0%	11.0%
10	우유 우유세팅 특가세팅 특가	행동형	PC	419	419	91.0%	11.0%	11.0%

시간대별 CVR - 오늘 vs 평소

오늘 2025-05-25



22시 광고 리스트

격차 +0.5%p - 오늘 CVR 13.0% - 평소 4.3%

CVR 오름차순 - 클릭 10건 이상

순위	광고명	광고 유형	매체	클릭수	인도수	CVR	CMA	평균수익률	등급	부진여부
1	군수 지부지·행정청 496	행동형	PC	11	0	0.0%	-	-	0	부진
2	군수 지부지·행정청 496	행동형	PC	11	0	0.0%	-	-	0	부진
3	군수 지부지·행정청 496	행동형	PC	11	0	0.0%	-	-	0	부진
4	군수 지부지·행정청 496	행동형	PC	11	0	0.0%	-	-	0	부진
5	군수 지부지·행정청 496	행동형	PC	11	0	0.0%	-	-	0	부진
6	군수 지부지·행정청 496	행동형	PC	11	0	0.0%	-	-	0	부진

문제 정의 및 해결 방안

문제 정의	해결 방안	효과
기존 광고 분류는 참여형에 과도하게 쏠려 유형별 성과 비교가 어려움	BERTopic 기반 행동·매체 2축 구조로 재분류 LLM 검수를 통한 분류 품질 개선	특정 유형 집중도 90% → 50%로 완화 광고 유형별 성과 비교 가능
CVR만으로는 수익성·스케일을 종합 평가하기 어려움	수익성·전환품질·스케일·속도를 종합 반영한 광고 품질 점수 모델 구축	광고 품질 객관적 평가 가능 광고 간 비교 · 운영 우선순위 설정 지원
광고 성과 저하를 운영 중에 조기 파악하기 어려움	D+3 초기 신호 기반 조기부진 예측 모델 설계 결과를 Streamlit 대시보드로 통합	부진 가능 광고 조기 점검 데이터 기반 의사결정 지원 및 운영 효율 향상

최종 산출물

광고품질점수 모델 : S/A/B/C/D 등급화

조기 점검 예측 모델 : D+3 기준

BERTopic 기반 광고 유형 재분류 기준

광고 운영 의사결정 지원 대시보드

데이터 전처리 파이프라인 구축 및 성능 최적화

분석 단위가 다른 원본 데이터를 EDA·모델링·대시보드에서 재사용 가능한 데이터마트로 재구성

분석 환경 한계

원본 데이터 5개 CSV (1.5GB)

로딩 소요 시간 11,599초 (약 3.2시간)

DuckDB · Polars 기반 최적화 파이프라인

CSV 원본 → Parquet 변환 → DuckDB 적재 → SQL 기반 파생테이블 생성 → Pandas·Polars 병행

	BEFORE (CSV)	AFTER (PARQUET)	개선율
데이터 총 용량	1,148 MB	117 MB	89.8% 절감
데이터 로딩 속도	10,468 초	1.9 초	5,622배 향상
메모리 점유 피크	1,870 MB	30 MB	98.4% 절감

파생 테이블	분석 단위
메인 퍼널 테이블 (main_funnel)	클릭키(click_key) = 1행
비용·마진 테이블 (finance_clean1 / finance_clean2)	적립 고유키(rwd_idx) = 1행
팩트 테이블 (ads_join_info_labeled)	클릭키(click_key) = 1행
광고 단위 성과 집계 테이블 (ad_outcome)	광고키(ads_idx) = 1행
유저 일자별 활동 테이블 (user_daily_activity_clean)	유저키(dvc_idx) × 클릭키(click_day) = 1행

전처리 최적화의 목적은 단순 속도 개선이 아니라, 반복 분석과 모델링이 가능한 데이터 구조를 만들기 위함

버토픽 광고 재분류

기존 광고 분류 체계로는 유형별 분석이 어려운 문제

- 문제 정의



기존 광고 유형은 일부 유형(참여형)에 쏠려 있어
실제 유저 행동(설치/가입/구매/시청 등)을 구분하지 못함
- BERTopic
선택 이유

광고 텍스트 안의 행동 의도를 의미 기반으로 묶기 위해 사용
단순 키워드가 아닌 토픽 후보 생성 후 LLM·수동 검수로 최종 정리
- 핵심 설계 원칙

- 희소 라벨(SNS/카카오/시청형) 먼저 확정 후 다수 라벨로 넘김 (참여형 쏠림 방지)
 - BERTopic은 최종 분류기가 아닌 검수 후보 압축 도구로만 활용
 - unknown 남기는 것이 틀린 라벨보다 안전 → 근거 없으면 미분류 유지

성과

구분	기존 광고유형	BERTopic 재분류
CVR 효과크기	0.04	0.09
분류 기준	매체형+행동형 혼재	매체형/행동형 분리
참여형 집중도	전체의 약 90%+ 쏠림	7개 행동유형으로 분산
시간대 분석	유형별 패턴 불명확	행동유형별 세분화
운영 활용	1차 구분만 가능	노출 전략 수립 가능



기존광고 유형(ads_type) → 행동유형(final_action) + 매체유형(final_media)
두 개의 축으로 분리

모델 1 : 광고 품질 점수화 (XGBOOST)

CVR · CTR 개별 지표의 수익성 착시 문제

➡ 수익성 · 전환품질 · 스케일 · 속도 4축 종합 품질 점수로 해결

점수 설계

광고 간 비교가 가능한 종합 품질점수



수익성 (마진)	35%
전환품질 (CVR)	30%
스케일 (완료 수)	20%
속도 (CTIT)	15%

모델 파이프라인

수익성·전환품질·규모·속도 지표 간 비선형 관계를 반영하기 위해 XGBoost 기반 점수화 모델을 사용



등급별 실제 성과와 비율



ROC-AUC
(test) 0.8347
목표 0.75 달성 ✓

train-test gap
0.0777
SAFE (<0.10) ✓

PR-AUC
(test) 0.6221
불균형 탐지
보조 지표

정밀도 (고성과)
49.0%
146 / (146+152)

S vs D 격차 67.5%p

등급 간 성과 차이 명확한 구분력 입증

평균 대비 최대 2.8배

S등급 집중 운영 시 고성과 광고 효율 극대화

운영 우선순위 1,445건

상위 40% (S·A 등급) 타겟팅 리소스 최적화

모델 2 : 광고 조기부진 예측 (RANDOMFOREST)


초기 3일 신호로 부진 가능 광고를 먼저 점검하는 운영 보조 기준 설계

I D+3일로 설계한 이유

초기 3일 CVR과 최종 CVR 상관계수 : $r = 0.910$
광고 종료 후 확인하는 사후 판단이 아니라,
D+3 초기 신호로 먼저 확인할 광고를 선별하기 위해 모델링

I 설계 원칙

완료수 계열 피쳐 제거: 최종 성과 정보 누수 방지
 $early_click < 10$ 은 관측 부족으로 ML 판단 보류
관측 부족 광고는 규칙 기반 별도 관리 대상으로 분리



I 모델 선택과 운영 적용

누수 피쳐 제거 조건에서 여러 모델을 비교하고,
성능과 안정성이 가장 적합한 RandomForest를 최종 선택
모델 결과는 '중단'이 아닌 '먼저 확인할 점검 신호'로 해석
과적합 가능성을 인지하고 운영 보조 기준으로 활용 범위를 제한

성능을 과장하지 않고, 운영 리스크를 줄이기 위한 보조 지표로 제한적으로 활용한다

초기 3일 CVR이 최종 CVR과 강하게 연결되어, D+3 시점 예측 기준으로 활용가능

